

Hệ Thống Phát Hiện Thao Túng Thị Trường

Báo cáo dự án Big Data

June 21, 2026

C++ Limit Order Book, Machine Learning, Apache Spark, Redis Stream, Graph Analytics và Shapley Value

- ① Bối cảnh và mục tiêu
- ② Kiến trúc hệ thống
- ③ Dữ liệu và đặc trưng
- ④ Huấn luyện Machine Learning
- ⑤ Alpha-Beta Search và Spark
- ⑥ Graph Analytics và Shapley Value
- ⑦ Kết quả demo
- ⑧ Hạn chế và hướng phát triển


Vấn đề cần giải quyết

Thị trường tài chính sinh ra dữ liệu số lệnh rất lớn. Các hành vi như spoofing, layering và wash trading có thể xuất hiện trong thời gian rất ngắn.

- Cần phát hiện tín hiệu thao túng gần thời gian thực
- Kết quả cảnh báo phải có khả năng giải thích để hỗ trợ kiểm tra nghiệp vụ
- Một mô hình đơn lẻ khó bao phủ cả dữ liệu số lệnh, kịch bản rủi ro và quan hệ tài khoản

- Mô phỏng và cập nhật **Limit Order Book** hiệu năng cao bằng C++
- Dùng đặc trưng số lệnh để phát hiện dấu hiệu spoofing
- Huấn luyện **Random Forest** bằng scikit-learn và Spark MLlib
- Phân tán phân tích kịch bản rủi ro bằng Spark
- Phát hiện cụm wash trading bằng đồ thị có hướng
- Tính Shapley Value để tìm tài khoản có vai trò trung tâm

Luồng xử lý tổng quát



Các thành phần chính

Thành phần	Vai trò
C++ Limit Order Book	Quản lý bid/ask, thêm lệnh, khớp lệnh, hủy lệnh và tính trạng thái thị trường.
Python Binding	Đóng gói lõi C++ thành module Python bằng pybind11.
ML Fast Filter	Trích xuất đặc trưng và dự đoán xác suất spoofing.
Search Engine	Sinh và đánh giá kịch bản bằng Alpha-Beta Search và heuristic risk score.
Spark Engine	Chạy song song nhiều kịch bản, tổng hợp thống kê bằng Spark SQL.
Graph/Shapley Analyzer	Phát hiện cụm giao dịch chéo và ước lượng tài khoản ringleader.
Output Recorder	Lưu kết quả chạy thành JSON/CSV theo từng run.

Nguồn dữ liệu

- FI-2010 làm dữ liệu nền cho Limit Order Book
- Replay JSON phục vụ demo tĩnh và streaming
- Spoofing episode tổng hợp được chèn để tạo nhiễu
- Wash trading được mô phỏng bằng giao dịch giữa tài khoản

Bộ đặc trưng

- **Spread:** best ask - best bid
- **Bid volume:** tổng khối lượng bên mua
- **Ask volume:** tổng khối lượng bên bán
- **Imbalance:** mất cân bằng thanh khoản
- **Cancel rate:** tỷ lệ hủy lệnh

Ý tưởng

Lớp Random Forest đóng vai trò bộ lọc nhanh: nhận snapshot số lệnh, trích 5 đặc trưng và trả về xác suất spoofing để quyết định có phân tích sâu hơn hay không

$$\text{Imbalance} = \frac{V_b - V_a}{V_b + V_a}$$

$$\text{CancelRate} = \frac{N_{cancel}}{N_{new} + N_{cancel}}$$

- Train/test dùng file nguồn khác nhau để giảm rủi ro rò rỉ dữ liệu
- Tầng này ưu tiên tốc độ, còn quyết định cuối cùng đến từ các lớp phân tích sau

Kết quả huấn luyện Random Forest

Chỉ số	scikit-learn	Spark MLlib
Số cây	200	20
Độ sâu tối đa	10	6
Train samples	50,000	50,000
Test samples	10,000	10,000
Accuracy	0.8461	0.7090
F1-score	0.2063	0.1319
ROC-AUC	0.8109	0.9107
Thời gian train	3.9 giây	4.57 giây

- Accuracy cao chịu ảnh hưởng mạnh từ dữ liệu mất cân bằng
- ROC-AUC cho thấy mô hình có khả năng phân tách tín hiệu spoofing tốt hơn ngẫu nhiên
- Spark MLlib hữu ích khi dữ liệu mở rộng ra nhiều partition hoặc nhiều worker node

Vai trò trong pipeline

Sau khi ML filter đánh dấu trạng thái nghi vấn, hệ thống sinh các kịch bản như thêm lệnh lớn, hủy lệnh hoặc giữ trạng thái để đánh giá tác động lên LOB

- Alpha-Beta Search giúp giảm số nhánh cần duyệt
- Quiescence search hạn chế kết luận nhầm từ biến động nhất thời

Heuristic risk score

$$\text{Risk} = 10 \cdot \text{Spread} + 50 \cdot \text{Imbalance} + 30 \cdot \text{CancelRate}$$

Nếu xuất hiện crossed book, hệ thống gán điểm rủi ro rất cao

Spark RDD

- Phân tán nhiều scenario độc lập
- Mỗi scenario trả về heuristic risk score
- Phù hợp với tính toán song song trên nhiều partition

Spark SQL

- Chuyển kết quả scenario thành DataFrame
- Tổng hợp average, max, min, standard deviation và percentile
- Tách rõ bước tính toán và bước phân tích thống kê

Phát hiện wash trading

- Mỗi tài khoản là một node
- Mỗi giao dịch là một cạnh có hướng
- Strongly connected components giúp tìm cụm giao dịch chéo nghi vấn

Ước lượng ringleader

$$\phi_i(v) = \frac{1}{M} \sum_{m=1}^M [v(S_m \cup \{i\}) - v(S_m)]$$

Tài khoản có Shapley Value cao nhất được xem là ứng viên ringleader

Kết quả đầu ra

- Snapshot LOB ban đầu
- Kết quả ML filter
- Kết quả scenario và Spark summary
- Community wash trading
- Shapley values và final result

Trường	Giá trị
Status	SPOOFING_AND_WASH_TRADING
Severity	CRITICAL
Ringleader	ACC_RINGLEADER
Community	ACC_1, ACC_2, ACC_3, ACC_RINGLEADER
Average risk	54.31
Maximum risk	78.91
Spoofing probability	1.0

Điểm mạnh

- Kiến trúc lai ghép: C++, Python, Spark, ML, Graph và Shapley Value.
- Có cả demo tĩnh và streaming/replay.
- Kết quả được lưu thành file để kiểm chứng.
- Spark MLlib đã sinh model và metrics.

Hạn chế

- Dataset mất cân bằng mạnh
- Hệ thống hiện ở mức mô phỏng và demo học thuật
- Spark chưa tối ưu cho pre-trade latency cực thấp
- Mô hình chưa có cơ chế cập nhật liên tục

- Bổ sung đặc trưng động theo thời gian: rolling imbalance, rolling cancel rate và biến động spread
- Tìm thêm dữ liệu thực tế hoặc benchmark chất lượng cao để tăng độ tin cậy của mô hình
- Xây dựng dashboard hoặc báo cáo tự động từ output để theo dõi kết quả demo
- Mở rộng streaming pipeline để tiến gần hơn tới môi trường vận hành thực tế

Cảm ơn!

Q&A